

Оптимизация путей доставки

Артём Матвеев

9 июля 2023 г.

Цель и задачи работы

Цель работы

Найти оптимальную схему развоза товаров по ПВЗ* со склада в д. Коледино.

*Пункт Выдачи Заказов

Задачи работы

- 1 Выполнить анализ данных.
- 2 Формализовать поставленную задачу.
- 3 Исследовать имеющиеся решения данной проблемы.
- 4 Реализовать собственное решение.
- 5 Провести оценку полученных результатов.
- 6 Привести решение в читабельный вид.

Таблица – Изначальные данные

count	max	max.1	dst_office_id	office_name	latitude	longitude
379	2023-04-24	507	105643	МО Одинцово Садовая 24	55.676228	37.248839
249	2023-04-24	507	133447	МО Кашира Ленина 15	54.844701	38.191166
345	2023-04-24	507	110999	МО Одинцово Сколковская 1Б	55.694942	37.324654
591	2023-04-24	507	5807	Подольск Победы 12	55.360190	37.512755
322	2023-04-24	507	3300	МО Свердловский Строителей 22	55.903330	38.155216

Distribution of a car load




Таблица – Совпадающие координаты

office_name	latitude	longitude
МСК Лётчика Бабушкина 6	55.859200	37.674346
МСК Ягодная 8к3	55.575078	37.674346
МО Королёв Тихонравова 44/2	55.937060	37.853607
МСК Николая Старостина 9	55.731524	37.853607

Capacitated Vehicle Routing Problem (CVRP)

Дано

- ❶ $G = (N, E)$ – полный граф, где:
 - $N = \{0, \dots, n\}$ – множество вершин.
 - $E = \{(i, j) : i, j \in V\}$ – множество рёбер.
 - $i \in N'$ – ПВЗ, $N' = N \setminus \{0\}$.
- ❷ $V = \{1, \dots, k\}$ – множество транспортных средств (ТС).
- ❸ Q – максимальная загрузка ТС.
- ❹ m_i – загрузка конкретного ПВЗ, $i = \{1, \dots, n\}$.
- ❺ d_{ij} – расстояние между двумя вершинами, $d_{ij} > 0$.
- ❻ Решающая переменная

$$x_{ijk} = \begin{cases} 1, & \text{если ТС } k \text{ едет от } i \text{ до } j \\ 0, & \text{иначе} \end{cases}$$

Найти

Minimize $\sum_{k \in V} \sum_{i \in N} \sum_{j \in N} d_{ij} \cdot x_{ijk},$

при условиях:

$$\textcircled{1} \quad \sum_{k \in V} \sum_{i \in N} x_{ijk} = 1, \forall j \in N$$

$$\textcircled{2} \quad \sum_{k \in V} \sum_{j \in N} x_{ijk} = 1, \forall i \in N$$

$$\textcircled{3} \quad \sum_{i \in N} m_i \sum_{j \in N} x_{ijk} \leq Q$$

$$\textcircled{4} \quad \sum_{j \in N} x_{0jk} = 1, \forall k \in V$$

$$\textcircled{5} \quad \sum_{i \in N} x_{i0k} = 1, \forall k \in V$$


$$\textcircled{6} \quad \sum_{i \in N} x_{ihk} - \sum_{j \in N} x_{hjk} = 0, \forall h \in N, \forall k \in V$$

$$\textcircled{7} \quad x_{ijk} = \{0, 1\}, i \neq j, \forall i, j \in N, \forall k \in V$$

$$\begin{pmatrix} 0 & 38 & 71 & \dots & 31 & 92 & 110 \\ 38 & 0 & 110 & \dots & 34 & 98 & 91 \\ 71 & 110 & 0 & \dots & 91 & 120 & 165 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \vdots & \vdots \\ 31 & 34 & 91 & \dots & 0 & 67 & 79 \\ 92 & 98 & 120 & \dots & 67 & 0 & 64 \\ 110 & 91 & 165 & \dots & 79 & 64 & 0 \end{pmatrix}$$

Особенности FastDepth

- Компилятор TVM¹ для внедрения модели на конкретное железо.
- Урезание сети после обучения с помощью алгоритма NetAdapt².




³Tianqi Chen, Thierry Moreau, Ziheng Jiang, et al. TVM: An Automated End-to-End Optimizing Compiler for Deep Learning. 2018.

⁴Tien-Ju Yang, Andrew Howard, Bo Chen, et al. NetAdapt: Platform-Aware Neural Network Adaptation for Mobile Applications. 2018.

Результаты экспериментов. FastDepth

on NYU Depth v2	Input Size	MACs [G]	RMSE	δ_1	CPU [ms]	GPU [ms]
Eigen <i>et al.</i> [11]	228×304	2.06	0.907	0.611	307	23
Eigen <i>et al.</i> [16] (AlexNet)	228×304	8.39	0.753	0.697	1391	96
Eigen <i>et al.</i> [16] (VGG)	228×304	23.4	0.641	0.769	2797	195
Laina <i>et al.</i> [12] (UpConv)	228×304	22.9	0.604	0.789	2384	237
Laina <i>et al.</i> [12] (UpProj)	228×304	42.7	0.573	0.811	3928	319
Xian <i>et al.</i> [37]	384×384	61.8	0.660	0.781	4429	283
This Work	224×224	0.37	0.604	0.771	37	5.6

Результаты экспериментов. FastDepth



Постановка задачи. Hu J. и др.³

Дано:

$$X^\ell = (x_i, y_i)_{i=1}^\ell, x_i := I \in \mathbb{R}^{228 \times 304 \times 3}, y_i := D^* \in \mathbb{R}^{228 \times 304 \times 1}$$

Найти модель $a: I \rightarrow D, D \in \mathbb{R}^{228 \times 304 \times 1}$

Критерий:

$$\mathcal{L}_{\text{RMSE}}(a, x) = \sqrt{\sum_{a(x) \in D} \frac{(a(x) - y(x))^2}{|D|}}$$

$$\mathcal{L}_{\delta_1}(a, x) = \max \left(\frac{a(x)}{y(x)}, \frac{y(x)}{a(x)} \right) < 1.25$$

Критерий на этапе применения КД с вспомогательными данными:

$$\mathcal{L} = \frac{1}{X^\ell} \sum_{p_i, g_i \in X^\ell} (\lambda L(N_s(p_i), N_t(p_i)) + (1 - \lambda) L(N_s(p_i), g_i))$$

$$p_i \equiv a(x_i), g_i \equiv y(x_i)$$

\mathcal{L} – функция потерь для обучения сети-ученика.


N_t и N_s – сети учителя и ученика.

$L = l_{\text{depth}} + l_{\text{grad}} + l_{\text{normal}}$, L – функция потерь из работы⁶.

⁵ Junjie Hu, Chenyou Fan, Hualie Jiang, et al. Boosting Light-Weight Depth Estimation Via Knowledge Distillation. 2021.

Модель состоит из:



- ❶ 4 слоя для слияния и сжатия признаков (FFC).
 - Поканальный механизм внимания⁷.
 - Слой свёртки.
- ❷ Масштабирование карт признаков (upsampling).
- ❸ Объединение карт признаков (concat).
- ❹ Два свёрточных слоя 5×5 (convs).



⁶ Junjie Hu, Mete Ozay, Yan Zhang, et al. Revisiting Single Image Depth Estimation: Toward Higher Resolution Maps with Accurate Object Boundaries. 2018.

⁷ Jie Hu, Li Shen, et al. Squeeze-and-Excitation Networks. 2017.


- Внедрение подхода дистилляции знаний (KD) с вспомогательными (auxiliary) данными.
 - ResNet-34 в качестве основы (backbone) для сети-учителя.
 - MobileNet-v2 в качестве основы для сети-ученика.



Результаты экспериментов. Ну J. и др.

Method	Backbone	Original set	Auxiliary set	Params (M) ↓	RMSE ↓	REL ↓	log 10 ↓	δ_1 ↑
Laina et al. [20]	ResNet-50	NYU-v2	–	60.6	0.573	0.127	0.055	0.811
Hu et al. [16]	ResNet-50	NYU-v2	–	63.6	0.555	0.126	0.054	0.843
Zhang et al. [48]	ResNet-50	NYU-v2	–	95.4	0.497	0.121	-	0.846
Fu et al. [10]	ResNet-101	NYU-v2	–	110.0	0.509	0.115	0.051	0.828
Hu et al. [16]	SeNet-154	NYU-v2	–	149.8	0.530	0.115	0.051	0.866
Chen et al. [4]	SeNet-154	NYU-v2	–	210.3	0.514	0.111	0.048	0.878
Chen et al.[3]	ResNet-101	NYU-v2	HC labeled data	163.4	0.376	0.098	0.042	0.899
Ours $N_s(\mathcal{X} \cup \mathcal{U})$	MobileNet-V2	NYU-v2	Unlabeled ScanNet	1.7	0.482	0.131	0.056	0.837
Ours $N_s(\mathcal{X} \cup \mathcal{U}')$	MobileNet-V2	NYU-v2	Labeled ScanNet	1.7	0.461	0.121	0.052	0.855

Результаты экспериментов. Ну J. и др.



Постановка задачи. DANet⁸

Дано:

$$X^\ell = (x_i, y_i)_{i=1}^\ell, \quad x_i := I \in \mathbb{R}^{228 \times 304 \times 3}, \quad y_i := D^* \in \mathbb{R}^{228 \times 304 \times 1}$$

Найти:

модель $a: I \rightarrow D, D \in \mathbb{R}^{228 \times 304 \times 1}$

$$a(x_i) = \sum_{n=1}^{N_b} \mathbf{P}_i(n) \mathbf{c}(n), \text{ где:}$$

$\mathbf{c} \in \mathbb{R}^{1 \times 1 \times N_b}$ – центральные значения ячеек глубины (depth bins).

$\mathbf{P} \in \mathbb{R}^{228 \times 304 \times N_b}$ – карты вероятности ячеек (bin-probability maps).

Критерий:

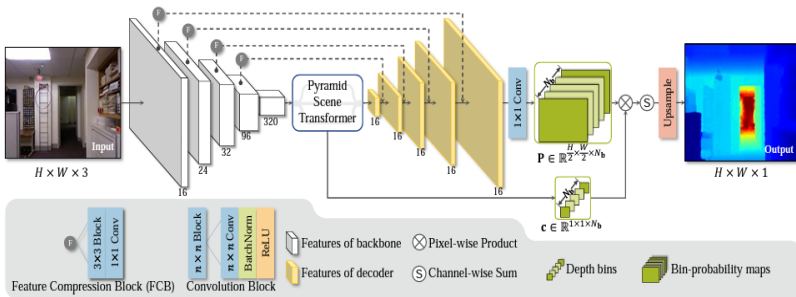
$$\mathcal{L}_{\text{RMSE}}(a, x) = \sqrt{\sum_{a(x) \in D} \frac{(a(x) - y(x))^2}{|D|}}$$

$$\mathcal{L}_{\delta_1}(a, x) = \max \left(\frac{a(x)}{y(x)}, \frac{y(x)}{a(x)} \right) < 1.25$$

⁸Fei Sheng, Feng Xue, Yicong Chang, et al. Monocular Depth Distribution Alignment with Low Computation. 2022.

Модель состоит из:

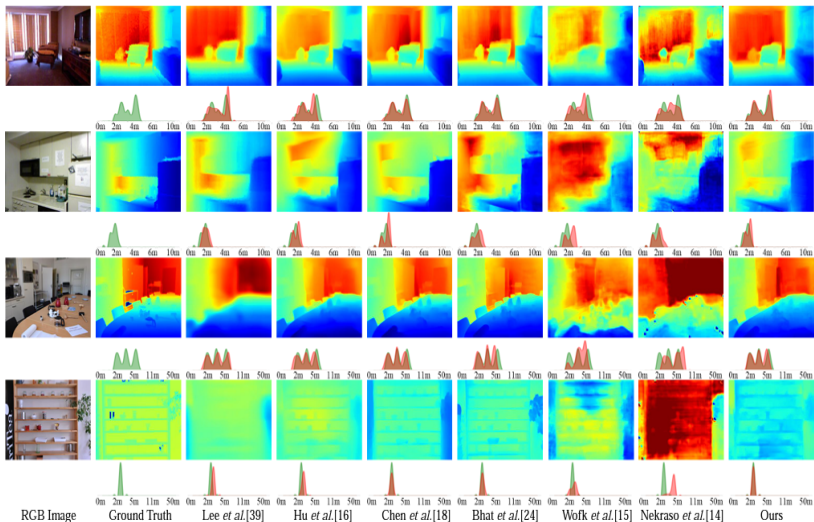
- 1 Энкодер (пирамидальный трансформер – PST).
- 2 Декодер.



Результаты экспериментов. DANet

Groups	Methods	Backbone	Resolution	FLOPs	Params	REL ↓	RMS ↓	log10 ↓	$\delta_1 \uparrow$	$\delta_2 \uparrow$	$\delta_3 \uparrow$
①	Eigen <i>et al.</i> [22]	VGG16	240 × 320	31G	240M	0.215	0.772	0.095	0.611	0.887	0.971
	Eigen <i>et al.</i> [21]	VGG16	228 × 304	23G	-	0.158	0.565	-	0.769	0.950	0.988
	Laina <i>et al.</i> [10]	ResNet50	240 × 320	17G	63M	0.127	0.573	0.055	0.811	0.953	0.988
	Fu <i>et al.</i> [11]	ResNet101	240 × 320	102G	85M	0.118	0.498	0.052	0.828	0.965	0.992
	Lee <i>et al.</i> [39]	DenseNet161	224 × 224	96G	268M	0.126	0.470	0.054	0.837	0.971	0.994
	Hu <i>et al.</i> [16]	ResNet50	228 × 304	107G	67M	0.130	0.505	0.057	0.831	0.965	0.991
	Chen <i>et al.</i> [18]	SENet154	228 × 304	150G	258M	0.111	0.420	0.048	0.878	0.976	0.993
	Yin <i>et al.</i> [17]	ResNet101	384 × 384	184G	90M	0.105	0.406	0.046	0.881	0.976	0.993
	Lee <i>et al.</i> [38]	ResNet101	416 × 544	132G	66M	0.113	0.407	0.049	0.871	0.977	0.995
②	Bhat <i>et al.</i> [24]	EfficientNet b5	426 × 560	186G	77M	0.103	0.364	0.044	0.902	0.983	0.997
	Wofk <i>et al.</i> [15]	MobileNet	224 × 224	0.75G	3.9M	0.162	0.591	-	0.778	0.942	0.987
	Nekrasov <i>et al.</i> [14]	MobileNet v2	480 × 640	6.49G	2.99M	0.149	0.565	-	0.790	0.955	0.990
	Yin <i>et al.</i> [17]	MobileNet v2	338 × 338	15.6G	2.7M	0.135	-	0.060	0.813	0.958	0.991
	Hu <i>et al.</i> [40]	MobileNet v2	228 × 304	-	1.7M	0.138	0.499	0.059	0.818	0.960	0.990
③	Hu <i>et al.</i> [16] †	EfficientNet b0	228 × 304	14G	5.3M	0.142	0.505	0.059	0.814	0.961	0.989
	Chen <i>et al.</i> [18] †	EfficientNet b0	228 × 304	8.22G	12M	0.135	0.514	-	0.828	0.963	0.990
	Yin <i>et al.</i> [17] †	EfficientNet b0	384 × 384	18G	4.6M	0.145	0.567	0.067	0.771	0.947	0.988
	Ours	EfficientNet b0	228 × 304	1.5G	8.2M	0.135	0.488	0.057	0.831	0.966	0.991

Результаты экспериментов. DANet



В ходе выполнения работы были выполнены все поставленные задачи, то есть:

- 1 Проанализирована работа Wofk D. и др. (FastDepth).
- 2 Проанализирована работа Hu J. и др.
- 3 Проанализирована работа Sheng F. и др. (DANet).

СПАСИБО ЗА ВНИМАНИЕ!